

AgenQA 代表性 Path View 样例题

Selected solver-facing questions for the AgenQA project showcase

本文展示三道 representative **Path View** sample questions，用于说明 AgenQA 生成题目的形态与难度来源。

这些样例都属于 solver-facing Path View：题面只给出最终求解所需的可见条件，中间 dependency path 被折叠，解题者需要自行恢复关键推理步骤。

Sample 1. FedAvg 收敛界中的学习率选择

Subject: Federated and Distributed Learning

Path View focus. 从 FedAvg 的 smoothness、non-IID 梯度异质性和通信轮数条件出发，恢复收敛上界中的学习率优化步骤。

Solver-facing question.

给定 FedAvg 设定：

- 全局目标函数为

$$F(w) = \sum_k \frac{n_k}{n} F_k(w),$$

其中 $F_k(w)$ 是客户端 k 的局部经验损失， $n_k = |D_k|$ ，且 $n = \sum_k n_k$ 。

- 每个客户端从 w^t 出发，以常数学习率 $\eta > 0$ 执行 $E > 1$ 步本地 SGD，再由服务器按权重平均聚合。
- 客户端数据 non-IID，梯度异质性由加权 RMS 量 G 表示：

$$G = \left(\sum_k \frac{n_k}{n} \|\nabla F_k(w) - \nabla F(w)\|^2 \right)^{1/2} \geq 0.$$

- 全局损失满足 L -smoothness：

$$F(w') \leq F(w) + \langle \nabla F(w), w' - w \rangle + \frac{L}{2} \|w' - w\|^2.$$

- 一共进行 T 轮全客户端参与通信， E, G, L, T 均为正数。

要求求出使时间平均平方梯度范数上界最小的学习率 η^* ，并给出优化后的最紧上界。最终答案只能使用 $F(w^0) - F(w^*)$ 、 L 、 E 、 G 、 T 。

Reference answer.

$$\eta^* = \sqrt{\frac{2[F(w^0) - F(w^*)]}{LE^2G^2T}}$$

$$\boxed{\frac{1}{T} \sum_{t=0}^{T-1} \|\nabla F(w^t)\|^2 \leq 2\sqrt{\frac{2LG^2[F(w^0) - F(w^*)]}{T}}}$$

Why this sample matters. 题面不直接给出中间收敛界的单步优化式，而要求 solver 从 FedAvg 设定中恢复出学习率选择与优化后上界。

Sample 2. Pointer-Generator Coverage Loss 的梯度路径

Subject: Natural Language Processing / Abstractive Summarization

Path View focus. 在 pointer-generator + coverage loss 结构中，恢复编码器隐藏状态 h_i 到总损失的两条梯度路径。

Solver-facing question.

给定软注意力 encoder-decoder:

$$e_{t,i} = \text{score}(s_t, h_i), \quad a_{t,i} = \frac{\exp(e_{t,i})}{\sum_j \exp(e_{t,j})}, \quad c_t = \sum_i a_{t,i} h_i.$$

组合训练损失为

$$L_{\text{total}} = L_{\text{NLL}} + \lambda L_{\text{cov}},$$

其中

$$\text{cov}_{t,i} = \sum_{t' < t} a_{t',i}, \quad L_{\text{cov}} = \sum_t \sum_i \min(a_{t,i}, \text{cov}_{t,i}).$$

编码器隐藏状态 h_i 是一个向量， $\lambda \geq 0$ 是固定标量， $\partial e_{t,i} / \partial h_i$ 表示标量 score 关于 h_i 的向量值 Jacobian。由于 score 函数未固定，所以保持为未展开形式。

要求推导 $\partial L_{\text{total}} / \partial h_i$ 的单一闭式符号表达。答案应同时捕捉：

- $h_i \rightarrow e_{t,i} \rightarrow a_{t,*}$ 的 score path;
- $h_i \rightarrow c_t \rightarrow L_{\text{NLL}}$ 的 context path。

Reference answer.

$$\boxed{\frac{\partial L_{\text{total}}}{\partial h_i} = \sum_t \left[a_{t,i} \left(g_{t,i} - \sum_j a_{t,j} g_{t,j} \right) \frac{\partial e_{t,i}}{\partial h_i} + a_{t,i} \frac{\partial L_{\text{NLL}}}{\partial c_t} \right]}$$

Why this sample matters. 题目要求 solver 把 softmax Jacobian、coverage dependency 和 context-vector path 合并，而不是只回答一个局部梯度公式。

Sample 3. TRADES 鲁棒训练目标的外层与内层条件

Subject: Machine Learning Security / Adversarial Robustness

Path View focus. 从 TRADES-style robust objective 出发，同时恢复外层 envelope-theorem gradient 与内层 PGD / KKT 条件。

Solver-facing question.

给定参数化深度神经网络 f_θ ，可行扰动集合为闭 L_p 球：

$$\{\delta : \|\delta\|_p \leq \varepsilon\}.$$

TRADES-style 目标为：

$$\min_{\theta} \mathbb{E}_{(x,y) \sim \mu} \left[L(f_\theta(x), y) + \beta \max_{\|\delta\|_p \leq \varepsilon} \text{KL}(f_\theta(x) \| f_\theta(x + \delta)) \right].$$

其中 $\text{KL}(f_\theta(x) \| f_\theta(x + \delta))$ 以 clean input distribution 为第一参数，以 perturbed input distribution 为第二参数。 $\delta^*(\theta)$ 表示内层 KL 最大化问题的解。

要求合并推导：

1. $\nabla_{\theta} \max_{\delta} \text{KL}(\cdot)$ 的 envelope-theorem 形式，以及 θ^* 处外层驻点条件；
2. 内层关于 δ 的归一化 PGD 更新规则；
3. 收敛时的 KKT 条件，包括梯度驻点、互补松弛和可行性。

Reference answer.

$$\nabla_{\theta} \max_{\|\delta\|_p \leq \varepsilon} \text{KL}(f_\theta(x) \| f_\theta(x + \delta)) = \nabla_{\theta} \text{KL}(f_\theta(x) \| f_\theta(x + \delta^*(\theta))).$$

$$\nabla_{\theta} \mathbb{E}_{(x,y) \sim \mu} [L(f_{\theta^*}(x), y)] + \beta \nabla_{\theta} \mathbb{E}_{(x,y) \sim \mu} [\text{KL}(f_{\theta^*}(x) \| f_{\theta^*}(x + \delta^*(\theta^*)))] = 0.$$

$$\delta_{t+1} = \Pi_{\|\cdot\|_p \leq \varepsilon} \left(\delta_t + \alpha \frac{\nabla_{\delta} \text{KL}(f_{\theta}(x) \| f_{\theta}(x + \delta_t))}{\|\nabla_{\delta} \text{KL}(f_{\theta}(x) \| f_{\theta}(x + \delta_t))\|_p} \right).$$

$$\nabla_{\delta} \text{KL}(f_{\theta}(x) \| f_{\theta}(x + \delta^*)) = \lambda \nabla_{\delta} \|\delta^*\|_p, \quad \lambda \geq 0.$$

$$\lambda(\|\delta^*\|_p - \varepsilon) = 0, \quad \|\delta^*\|_p \leq \varepsilon.$$

Why this sample matters. 题目覆盖 optimization / robustness reasoning: solver 需要同时处理外层参数优化、内层 adversarial maximization 和 constrained optimality conditions。